Questão 03

Revolutionizing enterprise search with notion, AWS & Cohere AI
Empresa

O Notion é uma plataforma global de produtividade e colaboração que funciona como um espaço de trabalho all-in-one workspace. A ferramenta permite que indivíduos e corporações criem bases de conhecimento interligadas, gerenciem projetos, organizem tarefas e estruturem documentos em um ambiente personalizável. Por ser tão versátil, tornou-se o repositório central de informações para milhões de equipes em todo o mundo.

Desafio

Com a utilização em massa dessa plataforma, os workspaces dos usuários se tornaram complexos e repletos de documentos. O grande problema do Notion era fornecer uma experiência unificada e fluida, onde as pessoas pudessem pesquisar em toda essa base de dados e encontrar a melhor informação rapidamente. Somado a isso, havia uma forte barreira linguística: a maioria dos usuários do Notion não são dos Estados Unidos e não possuem o inglês como primeira língua, exigindo um mecanismo de busca que compreendesse com precisão consultas em diversos idiomas.

Por que usar a Amazon?

A decisão de utilizar a AWS se baseou na parceria da provedora com a Cohere, especialista em inteligência artificial voltada para linguagem natural (AWS Partner Cohere Rerank service). A grande vantagem disso para o Notion foi a possibilidade de implementar o modelo de ranqueamento da Cohere diretamente através do Amazon SageMaker. Isso permitiu integrar uma IA moderna sem a necessidade de construir uma infraestrutura de processamento do zero, aproveitando um ambiente gerenciado e pronto para funcionar em produção.

Benefícios

- Precisão: o modelo da Cohere oferece um excelente sinal de relevância, entendendo o contexto e a intenção por trás do que o cliente está procurando, e não apenas palavras-chave exatas.
- Inclusão Global: o serviço possui uma capacidade avançada de compreensão multilíngue e tradução, flexibilizando o sistema para atender perfeitamente a base global de usuários do Notion.
- Performance: o uso do Amazon SageMaker garantiu a escalabilidade do sistema, permitindo o processamento de grandes volumes de buscas simultâneas e oferecendo suporte robusto a diversas regiões do mundo.

Arquitetura

A arquitetura do sistema funciona de forma integrada e em tempo real. Quando um usuário digita uma pesquisa no Notion, o banco de dados interno faz uma

recuperação inicial e separa uma lista de documentos potenciais. Essa lista preliminar e a consulta do usuário são enviadas para a nuvem da AWS, especificamente para um endpoint do Amazon SageMaker. Lá, o modelo Cohere Rerank analisa o significado semântico dos textos (independentemente do idioma) e reordena os documentos, colocando os mais relevantes no topo. O Notion recebe essa lista reordenada e exibe instantaneamente na interface do usuário.

Generating Dynamic Ads in Under 1 Second Using AWS Lambda with Booking.com

Empresa

A Booking.com é uma líder global em viagens digitais, fundada em 1996 como uma pequena startup holandesa. Hoje, a plataforma ajuda milhões de viajantes a encontrar acomodações, voos, aluguéis de carros e experiências em mais de 200 países. Para se conectar com esses viajantes, a empresa investe fortemente na execução de anúncios dinâmicos em diversas redes sociais.

Desafio

A equipe de ad-tech precisava adicionar automaticamente conteúdos dinâmicos, como preços atualizados, localização e elementos de marca sobre as imagens das propriedades para criar anúncios atrativos. Antes, esse processo era realizado por um fornecedor terceirizado, o que custava milhões de dólares anuais e era extremamente limitante. A dependência de terceiros dificultava a personalização de templates, testes de novas abordagens criativas e resultava em integrações complexas que não ofereciam visibilidade sobre a performance ou facilidade para resolver falhas.

Por que usar a Amazon?

A liderança da Booking.com já havia identificado a Amazon Web Services como provedora estratégica para sua transformação em nuvem. A equipe técnica percebeu que construir uma arquitetura 100% serverless na AWS forneceria a escalabilidade e a flexibilidade necessárias para internalizar a operação. O fator decisivo foi a capacidade de utilizar os serviços da AWS prontos para uso em larga escala, permitindo que os engenheiros focassem no desenvolvimento da solução sem se preocupar com configurações complexas de infraestrutura de servidores.

Benefícios

- Redução de custos: A eliminação das taxas da ferramenta terceirizada e o modelo de pagamento sob demanda da arquitetura serverless reduziram os custos operacionais em 90%.
- Performance e Escala: O sistema processa mais de 1.000 requisições por segundo, entregando imagens em menos de 1 segundo com 99.9% de disponibilidade, lidando tranquilamente com os 200 feeds e 1.5 milhão de listagens de hotéis.

- Controle Criativo e Visibilidade: O time de marketing agora pode testar e inovar rapidamente, enquanto a equipe de engenharia obteve visibilidade total e em tempo real sobre a saúde do sistema.

Arquitetura

O fluxo do sistema opera sob demanda e com baixíssima latência. Quando uma rede social precisa de uma imagem para um anúncio, ela envia uma requisição para o Amazon CloudFront (serviço de entrega rápida de conteúdo). Essa requisição passa por um API Gateway, que atua como camada de segurança da Booking.com. Em seguida, o AWS Lambda (serviço de computação serverless) é acionado. O Lambda recupera a foto base do hotel e os elementos gráficos (como logos e fontes) armazenados no Amazon S3. O próprio Lambda renderiza a imagem final sobrepondo os dados dinâmicos de preço e local, devolvendo-a via CloudFront para o parceiro de rede social. Todo esse ecossistema é monitorado continuamente pelo Amazon CloudWatch para garantir a estabilidade.

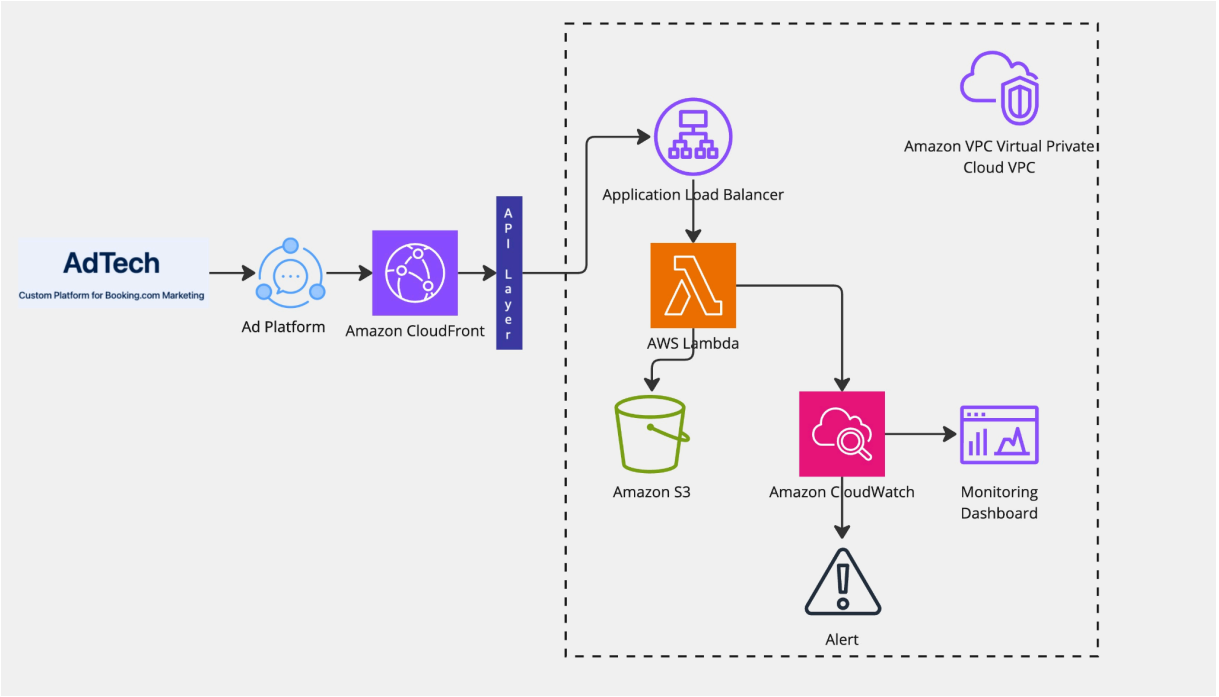

Questão 04

Spotify: The future of audio. Putting data to work, one listener at a time.

Empresa

O Spotify é um serviço líder global de streaming de áudio, lançado no final de 2008. Caracterizado por um grande crescimento impulsionado pela tecnologia, a plataforma oferece a centenas de milhões de usuários ativos em dezenas de mercados acesso a um vasto catálogo com mais de 50 milhões de músicas e

podcasts. A empresa tem uma cultura voltada para a engenharia de software, com quase metade de sua força de trabalho global dedicada exclusivamente a construir, lançar e manter seus produtos.

Desafio

O mercado de streaming de áudio é altamente competitivo. O grande desafio do Spotify era manter o ritmo acelerado de desenvolvimento de produtos e aprimorar a personalização (como motores de recomendação e descoberta de músicas), enquanto lidava com o peso de gerenciar sua própria infraestrutura física. O escopo técnico era massivo: a empresa precisava migrar 1.200 serviços online, processamentos complexos baseados em directed acyclic graphs e 20.000 execuções diárias de jobs de seus data centers locais para um ambiente que suportasse sua escala global sem interromper a experiência do usuário.

Por que usar a Google Cloud?

A decisão de migrar para a Google Cloud foi motivada pela necessidade de abstrair a complexidade operacional da infraestrutura. O Spotify precisava que seus engenheiros parassem de gastar tempo com manutenções de baixo valor agregado em servidores físicos e focassem no core business: o desenvolvimento de novos recursos, data analytics e machine learning. A Google Cloud ofereceu um ecossistema gerenciado com serviços amigáveis para desenvolvedores, permitindo que a equipe iterasse muito mais rápido sobre as necessidades reais do negócio.

Benefícios

A transição resultou em um ganho drástico de agilidade. Com a automação de processos, o Spotify aprimorou a personalização de forma segura (preservando a privacidade dos dados) e impulsionou inovações como a curadoria de podcasts. Além dos usuários finais, os artistas também foram beneficiados com a criação de dashboards analíticos detalhados, permitindo que tomassem decisões informadas sobre turnês e lançamentos com base no comportamento dos fãs. O impacto dessa infraestrutura robusta e da inovação contínua refletiu-se diretamente no crescimento do negócio, com um aumento de 29% no número de assinantes premium em apenas um ano.

Arquitetura

A espinha dorsal dessa nova fase está apoiada na rede global da Google Cloud, que hoje processa bilhões de reproduções diárias do Spotify. O fluxo de arquitetura de dados utiliza blocos de construção essenciais que removem os gargalos do backend. O BigQuery atua como a principal ferramenta para a análise massiva de dados em nuvem; o Pub/Sub é utilizado para gerenciar a mensageria e o tráfego de eventos, acelerando o desenvolvimento de aplicações de software; e o Dataflow é aplicado para o processamento contínuo e análise robusta de dados históricos e em tempo real. Juntos, esses componentes formam uma arquitetura altamente escalável que sustenta o motor de personalização e as integrações da plataforma.

Questão 05

O apagão na nuvem da Amazon, ocorrido em 20 de outubro de 2025, serve como um estudo de caso emblemático sobre a vulnerabilidade de serviços digitais globais. De acordo com informações publicadas pelo portal g1 pelos jornalistas Darlan Helder e Victor Hugo Silva, uma falha crítica na Amazon Web Services (AWS) causou uma instabilidade que se estendeu por cerca de 15 horas, afetando mais de 500 empresas e milhões de usuários ao redor do mundo. Serviços essenciais e aplicativos populares como iFood, Mercado Livre, PicPay, Zoom e diversas plataformas de jogos enfrentaram dificuldades operacionais significativas devido a esse incidente.

A origem do problema foi localizada na região US-EAST-1, situada no norte da Virgínia, nos Estados Unidos, que é uma das infraestruturas mais antigas e centrais da AWS. A falha técnica manifestou-se inicialmente com taxas de erro elevadas no DynamoDB, o sistema de banco de dados da empresa, e no serviço de servidores virtuais EC2. O ponto nevrálgico da pane foi uma falha no processo de resolução de DNS, que impediu os computadores de traduzirem nomes de domínios em endereços de IP, impossibilitando a comunicação entre os sistemas.

Esse evento demonstrou que, embora a computação em nuvem ofereça escalabilidade e redução de custos, a centralização de serviços em uma única região geográfica pode criar um ponto único de falha. Especialistas citados na reportagem, como Thiago Ayub e Thiago Bordini, ressaltaram que muitas empresas subestimam os riscos de interrupção e deixam de adotar medidas de redundância e backup em múltiplas regiões. O restabelecimento total dos serviços só ocorreu no início da noite daquela segunda-feira, após a AWS aplicar correções nos sistemas de banco de dados e na capacidade elástica de seus servidores, evidenciando a dependência crítica que a economia digital moderna possui dos grandes provedores de nuvem.